

(a) False-alarm $ASR_{[FP]}$

Model	FA			MECTA			MSA			RLOFFA			RLONA			CSA		
	FGSM	BIM	PGD	FGSM	BIM	PGD	FGSM	BIM	PGD	FGSM	BIM	PGD	FGSM	BIM	PGD	FGSM	BIM	PGD
DT	0.00	0.00	0.00	0.00	0.00	0.01	0.00	0.00	0.01	0.00	0.00	0.00	0.01	0.01	0.01	0.00	0.00	0.00
RF	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.01	0.01	0.01	0.00	0.00	0.00
ET	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.01	0.01	0.00	0.00	0.00	0.00
XGBoost	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.01	0.01	0.01	0.00	0.00	0.00
DNN	0.00	0.00	0.00	0.00	0.00	0.01	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00

(b) Missed-attack $ASR_{[FN]}$

Model	FA			MECTA			MSA			RLOFFA			RLONA			CSA		
	FGSM	BIM	PGD	FGSM	BIM	PGD	FGSM	BIM	PGD	FGSM	BIM	PGD	FGSM	BIM	PGD	FGSM	BIM	PGD
DT	0.00	0.00	0.22	0.67	0.67	0.58	0.00	0.00	0.35	0.44	0.44	0.88	0.02	0.02	0.77	N/A	N/A	N/A
RF	0.00	0.00	0.23	0.67	0.67	0.58	0.00	0.00	0.41	0.45	0.45	0.92	0.02	0.02	0.66	N/A	N/A	N/A
ET	0.00	0.00	0.00	0.67	0.67	0.58	0.01	0.01	0.17	0.44	0.44	0.92	0.02	0.02	0.32	N/A	N/A	N/A
XGBoost	0.00	0.00	0.51	0.67	0.67	0.92	0.00	0.00	0.50	0.44	0.44	0.94	0.02	0.02	0.73	N/A	N/A	N/A
DNN	0.04	0.04	0.04	1.00	1.00	1.00	0.21	0.21	0.21	0.71	0.71	0.79	0.11	0.11	0.33	N/A	N/A	N/A

ASR (averaged over $\varepsilon \in \{1, 5\}$)

1.0

0.8

0.6

0.4

0.2

0.0